

A100 光电 MoE 与 Qwen3VL 基线：时间、功率与能效测量说明

固定版本 · 200 次正式测量 · 无专门预热 · 第 1 次计入

摘要

本文件定义并复核七项已完成任务的推理边界、计时方法、功率输入与能量公式。04（ABO 文搜图）与 08（ABO clean 文生图）仅预留，不填入任何推测结果。性能取绑定检查点的完整测试集结果；基线速度取测试集顺序前 200 项；Ours 对固定形状、GPU 驻留的任务电子核连续执行 200 次。两者均仅加载模型一次，不执行显式预热，且保留第 1 次测量。

测量边界与时钟

Qwen3VL 基线使用 Synchronized Wall：在第一个原生 Vision Transformer block 的 pre-hook 处开始，经过所需 Vision/Language blocks 与任务读出头，在最终输出就绪并完成 CUDA synchronize 后停止。模型加载、文件解码、processor/tokenizer 与 CPU→GPU 搬运不在该区间内。

Ours 的电子时间使用 CUDA Event，并仅串行计入 CCD 后非线性与学习式读出、光路由算术、必要 bridge/merger 与任务头；与光传播并行的残差支路不进入关键路径。每个电子核执行 200 次，报告全部 200 次（含第 1 次）的均值。CCD 裁剪/堆叠、排版、SLM 编码、文件 I/O、搬运以及通用整场张量融合不进入该窄口径。

单次物理传播固定为 1.0447 ms = 0.714 ms（高速 SLM）+ 0.300 ms（曝光）+ 0.0307 ms（812×812 ROI 相机读出）。含语言的任务与双层视频质量网络为 6 次传播；LSP 与 SALICON 为仅视觉的 3 次传播。

功率与能量计算

光学设备功率为 80.358 W：激光器 9.679 W、相位 SLM 5.595 W、CCD 14.303 W、高速 SLM 34.225 W + 16.556 W。控制机箱固定 41.388 W；Ours 的 A100 固定 62.842 W。基线机箱固定 338.2 W，A100 板卡功率按各任务连续推理阶段的 nvidia-smi active mean 读取，不做空载扣除。

Ours: $E = t_{\text{光}} \times (80.358 + 41.388) + t_{\text{电}} \times (41.388 + 62.842)$

Baseline: $E = t_{\text{Wall}} \times (338.2 + P_{\text{A100,active}})$

速度提升 = $t_{\text{Baseline}} / t_{\text{Ours}}$ ；能效提升 = $E_{\text{Baseline}} / E_{\text{Ours}}$ ；能量降低 = $1 - E_{\text{Ours}} / E_{\text{Baseline}}$ 。

主要结果

序号	任务	Ours ms	Baseline ms	Ours J	Baseline J	速度×	能效×
01a	LGVQ temporal quality	10.524	1188.386	1.207	462.113	112.92	382.96
01b	LGVQ spatial quality	10.132	73.784	1.166	28.790	7.28	24.70
02	ABO image-to-text retrieval	7.872	40.659	0.930	16.961	5.17	18.23
03	ABO image-to-image retrieval	7.781	44.930	0.921	19.048	5.77	20.69
05	LSP keypoint detection	5.084	17.463	0.585	7.016	3.43	12.00
06	SALICON saliency	5.055	17.797	0.582	7.163	3.52	12.31
07	OpenMoji	9.037	44.298	1.052	18.514	4.90	17.60

	semantic interaction						
--	-------------------------	--	--	--	--	--	--

注：LGVQ temporal 的 Ours 是 16 个视频共享一个光场的批次延迟；基线为 16 次 batch=1 调用之和。其余行均为单样本。表中所有派生数值由同目录 `calculated_summary.json/csv` 生成。

运算量口径

统一采用 1 个实数 MAC = 2 OP。基线通过真实前向钩子统计第一个 Vision block 后实际执行的 Linear、Conv 与注意力 QK/AV；不把激活、归一化、池化、索引、softmax 等无 MAC 操作虚构为 MAC。Ours 的传播运算量按 478×478 个模式的稠密复数线性变换等效计数，并明确标注为 effective TOP；A100 侧标注为 achieved MAC-derived TOP。二者不能与芯片数据手册峰值 TOPS 混用。

序号	Ours effective TOP	Baseline achieved TOP	Ours TOPS/W	Baseline TOPS/W	提升×
01a	0.6270	39.2022	0.5196	0.0848	6.12
01b	0.6266	2.4501	0.5375	0.0851	6.32
02	0.6265	0.2971	0.6735	0.0175	38.45
03	0.6265	0.2999	0.6804	0.0157	43.21
05	0.3135	0.1293	0.5360	0.0184	29.08
06	0.3135	0.1260	0.5390	0.0176	30.65
07	0.6266	0.3106	0.5957	0.0168	35.51

版本、数据与可复核性

每项报告均保留：逐样本/逐调用时间 CSV、连续功率采样 CSV、进程占用审计、模型/检查点/源码 SHA-256、运行命令与环境。原始服务器目录为 `/DATA/DATA1/guest3/2026OpticsMoE_a100_measurements/20260927_demo_energy_efficiency_a100`；本地镜像位于本说明同目录的 `raw_remote`，并另按 `baseline/ours/任务编号` 整理。

LSP 的红框展示值 0.7353 尚未找到可严格绑定的结果文件；当前可追溯的 Ours 完整测试结果为 0.7347857143。为避免学术性替换，本报告保留精确绑定值。OpenMoji 基线固定为新布局 0.8120，不混用旧结果 0.8420。

质量控制

- A100 物理索引固定为 6；每个正式 profiler 在测量前后检查无其他计算 PID。
- 01 的首轮功率误读物理 GPU 0 已被识别并作废；正式结果为重测后的物理 GPU 6 数据，作废文件保留在 `audit_rejected_wrong_gpu0_power`。
- 所有计时均无显式 warm-up，且第 1 项包含在均值中；不通过删除慢启动样本缩短结果。
- 04、08 状态为 reserved，待模型定稿后按相同协议补测。